

基于 ReLU^k 有限神经元空间的 L^2 与 H^1 投影数值研究

Yingxi Ye

研究汇报

2026 年 6 月 23 日

摘要

本文研究基于 ReLU^k 函数构造的有限神经元空间中的 L^2 与 H^1 投影问题。主要思想是固定神经网络的内部参数，只优化外层线性系数，从而将原本非凸的神经网络训练问题转化为线性的投影问题或加权最小二乘问题。

本文的目的在于对当前阶段的数值实验进行整理和分析。一方面观察当神经元数量增加时投影误差的衰减行为，另一方面讨论实际计算中出现的数值问题，包括积分方法的选择、所需积分点数、最小二乘矩阵的条件数以及参考方法的几何构造成本。二维和三维实验表明，线性化 ReLU^k 神经元空间能够得到较好的近似效果，但最终性能依赖于逼近误差、积分误差和数值稳定性之间的平衡。

1 研究背景与动机

神经网络近年来被广泛用于函数逼近和偏微分方程的数值求解。在 PINN 或 Deep Ritz 等方法中，通常需要同时优化神经网络的内部参数和外层参数。这样的优化问题一般是非凸的，因此在数值上可能较难控制。

一种替代思路是考虑线性化神经网络。具体来说，提前固定神经元的内部参数，只求解外层线性系数。这类方法与 random feature methods 和 extreme learning machines 有密切关系。它的优势在于数学结构更加简单：逼近空间变成有限维线性空间，系数计算可以转化为线性最小二乘问题。

从数值分析角度看，这一框架非常自然。它涉及基函数构造、数值积分、矩阵组装、线性求解器稳定性以及计算复杂度等问题，与有限元方法、谱方法和配置点方法中遇到的问题有一定相似性。因此，本文主要通过数值实验研究这类有限神经元空间在 L^2 和 H^1 投影中的表现。

2 理论框架

2.1 ReLU^k 有限神经元空间

考虑计算区域

$$\Omega = [-1, 1]^d, \quad d = 2 \text{ 或 } d = 3,$$

以及激活函数

$$\sigma_k(t) = (t)_+^k = \max(t, 0)^k.$$

对于固定参数 $(w_j, b_j) \in \mathbb{R}^d \times \mathbb{R}$, 定义基函数

$$\phi_j(x) = \sigma_k(w_j \cdot x + b_j), \quad j = 1, \dots, n.$$

由这些基函数张成的有限神经元空间为

$$L_n^k = \text{span}\{\phi_1, \dots, \phi_n\}.$$

待求近似函数写作

$$u_n(x) = \sum_{j=1}^n a_j \phi_j(x),$$

其中只有外层系数 a_j 是未知量。

由于 ReLU^k 具有齐次性, 可以将参数归一化到单位球面上。令

$$\theta_j = (w_j, b_j) \in \mathbb{S}^d \subset \mathbb{R}^{d+1}, \quad \tilde{x} = (x, 1).$$

于是基函数可以写成

$$\phi_j(x) = \sigma_k(\theta_j \cdot \tilde{x}).$$

参数点 θ_j 的分布对逼近效果有重要影响。当这些点在球面上分布较均匀时, 空间 L_n^k 在 Sobolev 空间中具有较好的逼近性质。

2.2 L^2 投影

函数 u 在 L_n^k 上的 L^2 投影定义为

$$u_n = \arg \min_{v \in L_n^k} \|u - v\|_{L^2(\Omega)}.$$

将 $u_n = \sum_{j=1}^n a_j \phi_j$ 代入后, 可以得到线性系统

$$Ma = f,$$

其中

$$M_{ij} = \int_{\Omega} \phi_i(x) \phi_j(x) \, dx, \quad f_i = \int_{\Omega} u(x) \phi_i(x) \, dx.$$

矩阵 M 是 Gram 矩阵, 类似于有限元方法中的质量矩阵。

2.3 H^1 投影

对于 H^1 投影, 需要最小化

$$\|u - u_n\|_{H^1(\Omega)}^2 = \|u - u_n\|_{L^2(\Omega)}^2 + \|\nabla u - \nabla u_n\|_{L^2(\Omega)}^2.$$

基函数的梯度为

$$\nabla \phi_j(x) = k(w_j \cdot x + b_j)_+^{k-1} w_j.$$

因此, H^1 投影不仅涉及质量矩阵, 还涉及刚度矩阵:

$$S_{ij} = \int_{\Omega} \nabla \phi_i(x) \cdot \nabla \phi_j(x) \, dx.$$

与 L^2 情况相比, H^1 投影对数值积分和矩阵条件数更加敏感, 因为它包含基函数的导数信息。

2.4 理论收敛率

对于 ReLU^k 有限神经元空间, 理论上如果参数在球面上接近均匀分布, 可以得到如下形式的逼近率:

$$\inf_{v \in L_n^k} \|u - v\|_{H^m(\Omega)} \lesssim n^{-\frac{1}{2} - \frac{2(k-m)+1}{2d}}.$$

因此, 在 $d = 2$ 且 $k = 3$ 的情况下, 预期有

$$\varepsilon_n^{L^2} \sim n^{-9/4}, \quad \varepsilon_n^{H^1} \sim n^{-7/4}.$$

这些理论斜率可以作为理解数值实验的参考。不过, 实际误差不仅由逼近空间决定, 还会受到数值积分、线性求解器以及矩阵条件数的影响。

3 数值格式

3.1 加权最小二乘形式

一种直接做法是组装质量矩阵和刚度矩阵。然而, 显式形成 normal equations 可能带来数值不稳定。设 Φ 是基函数在积分点上的取值矩阵, 则有

$$M \approx \Phi^\top W \Phi.$$

此时矩阵条件数会被放大:

$$\kappa(\Phi^\top W \Phi) \simeq \kappa(\sqrt{W} \Phi)^2.$$

因此, 本文采用加权最小二乘形式:

$$\min_a \|Aa - y\|_2,$$

其中

$$A_{qj} = \sqrt{\omega_q} \phi_j(x_q), \quad y_q = \sqrt{\omega_q} u(x_q).$$

对于 H^1 投影, 还需要加入导数对应的行:

$$A = \begin{bmatrix} \sqrt{W} \Phi \\ \sqrt{W} \partial_{x_1} \Phi \\ \dots \\ \sqrt{W} \partial_{x_d} \Phi \end{bmatrix}, \quad y = \begin{bmatrix} \sqrt{W} u \\ \sqrt{W} \partial_{x_1} u \\ \dots \\ \sqrt{W} \partial_{x_d} u \end{bmatrix}.$$

这种形式可以直接使用基于 SVD 的稳健最小二乘求解器, 从而避免 normal equations 中条件数平方放大的问题。

3.2 积分方法比较

本文比较了几种不同的积分点和权重生成方式。

QUAD-box. 将计算区域划分为二维小方块或三维小立方体, 在每个小区域上使用张量积 Gauss-Legendre 积分。该方法简单、确定性强, 并且不需要显式构造 ReLU 的激活区域。

Monte Carlo 与 Sobol-QMC. Monte Carlo 方法使用均匀随机点；Sobol-QMC 方法使用低差异序列点。这两类方法在高维中较容易实现，也适合快速构造加权最小二乘问题。

POLY 与 QUAD-simplex. 对于两个基函数

$$\phi_i(x) = (w_i \cdot x + b_i)_+^k, \quad \phi_j(x) = (w_j \cdot x + b_j)_+^k,$$

其乘积只在两者同时激活的区域非零。因此定义有效区域

$$D_{ij} = \Omega \cap \{w_i \cdot x + b_i > 0\} \cap \{w_j \cdot x + b_j > 0\}.$$

在二维中， D_{ij} 是凸多边形；在三维中，它是凸多面体。POLY 和 QUAD-simplex 方法利用这一几何结构进行积分。它们精度较高，但由于需要对每一对基函数 (i, j) 构造有效区域，计算成本会随着神经元数量快速增加。

Schéma méthodologique de l'étude numérique




图 1: 数值方法示意图。先固定神经元内部参数，再通过加权最小二乘求解外层线性系数。

4 数值实验

4.1 光滑目标函数

首先考虑光滑目标函数。二维情形为

$$u(x, y) = \sin\left(\frac{\pi x}{2}\right) \sin\left(\frac{\pi y}{2}\right).$$

三维情形为

$$u(x, y, z) = \sin\left(\frac{\pi x}{2}\right) \sin\left(\frac{\pi y}{2}\right) \sin\left(\frac{\pi z}{2}\right).$$

这些函数用于观察当神经元数量增加时，空间 L_n^k 的基本逼近行为。




图 2: 二维光滑目标函数下 L^2 与 H^1 投影的相对误差。

图 2 显示, 当 n 增大时, 相对误差整体呈现规律下降。QUAD-box、MC-Sobol 和 POLY 的误差曲线在较大范围内比较接近, 说明在该二维光滑例子中, 主要误差来自有限神经元空间本身的逼近误差, 而不是数值积分误差。

QUAD-box 与 POLY 的接近也说明, 小方块 Gauss 积分已经能够较好近似连续投影, 而不一定需要显式构造所有有效区域 D_{ij} 。同时, H^1 误差相对更敏感, 因为它包含导数信息, 更容易受到局部误差和系数扰动的影响。




图 3: 三维光滑目标函数下 L^2 与 H^1 投影的相对误差。

图 3 表明该方法在三维中仍然有效。虽然三维积分成本更高, 有效区域的几何构造也更加复杂, 但误差仍然随着神经元数量增加而下降。三种方法给出的趋势基本一致, 说明加权最小二乘框架在三维中也具有较好的可扩展性。

4.2 所需积分点数

当逼近误差随着神经元数量 n 增大而下降时, 必须使用足够多的积分点, 使积分误差不会主导最终误差。

本文使用 POLY 作为确定性参考。对于每个 n , 寻找使 MC、Sobol 或 QUAD-box 的误差接近 POLY 参考误差的最小积分点数, 并称其为所需积分点数。

对于 Monte Carlo, 积分误差通常为

$$O(N^{-1/2}).$$

对于 Sobol-QMC, 理想情况下可以期待更好的行为, 接近

$$O(N^{-1}),$$

其中可能带有对数因子。结合 $d = 2$ 、 $k = 3$ 时的理论逼近率, 可以得到以下启发式关系:

$$N_{MC,L^2} \sim n^{9/2}, \quad N_{MC,H^1} \sim n^{7/2},$$

以及

$$N_{QMC,L^2} \sim n^{9/4}, \quad N_{QMC,H^1} \sim n^{7/4}.$$




图 4: 达到与 POLY 参考误差相近精度所需的积分点数。虚线表示 Monte Carlo 和 Sobol-QMC 的理论参考斜率。

图 4 显示, 随着 n 增加, 所需积分点数也整体增加。这是合理的: 神经元空间越丰富, 理论逼近误差越小, 因此积分误差也必须进一步降低, 才能使离散投影接近连续投影。

不过，实验曲线并不完全遵循理论斜率。这并不一定说明理论失效，因为这里观测的是最终最小二乘解的误差，而不是单独的积分误差。实际结果还会受到矩阵条件数、候选点数网格以及误差判定阈值的影响。当 n 较大时，产品积分中的小扰动也可能被病态矩阵放大，从而导致误差曲线出现波动。

4.3 低正则目标函数

为了进一步测试方法的鲁棒性，考虑一个正则性较低的二维目标函数：

$$u(x, y) = \left| x - \frac{1}{2} \right|^{k+\frac{3}{2}} + \left| y - \frac{1}{2} \right|^{k+\frac{3}{2}}.$$

该函数不如正弦函数光滑，在 $x = 1/2$ 和 $y = 1/2$ 附近具有较低的局部正则性。




图 5: 二维低正则目标函数下 L^2 与 H^1 投影的相对误差。

图 5 显示，即使目标函数正则性较低， L^2 和 H^1 误差仍然随着 n 增加而下降。这说明前面在光滑正弦函数上观察到的良好效果并不完全依赖于目标函数的高光滑性，有限神经元空间仍然能够逼近带有弱奇异性或局部低正则性的函数。

不过，曲线末端可能不如光滑情形稳定。一方面，低正则函数的渐近收敛率可能在有限范围的 n 上更难观察；另一方面，当误差已经较小时，积分误差和矩阵条件数的影响会变得更加明显。

4.4 计算成本与数值稳定性

最后比较三维 H^1 投影中的计算时间。这里将总时间分解为积分点生成、矩阵组装、最小二乘求解以及总计算时间。




图 6: 三维 H^1 投影中的计算时间分解和不同方法对比。

图 6 表明, MC-Sobol 在总时间上最快。这是因为该方法直接在区域中生成积分点, 不需要构造 ReLU 激活区域的几何结构。QUAD-box 的计算成本更高, 但仍然较为稳定和可控, 因为它只需要在规则小立方体上生成 Gauss 积分点。

POLY 方法的成本明显更高, 尤其体现在组装时间和总时间上。原因在于它需要对每一对基函数构造有效区域 D_{ij} 。在三维中, 该区域是凸多面体, 需要进行顶点搜索、边界恢复和剖分等几何操作, 因此成本会随着 n 快速增长。

这一结果说明, POLY 更适合作为确定性参考方法, 而不适合直接用于大规模计算。相比之下, QUAD-box 与 Sobol-QMC 在三维中更适合实际数值实现。

5 讨论

数值实验主要说明了以下三点。

首先, ReLU^k 有限神经元空间在 L^2 和 H^1 范数下具有较强的逼近能力。无论是在二维还是三维中, 无论目标函数是光滑还是正则性较低, 误差整体都随神经元数量增加而下降。

其次, 数值积分质量在大规模情况下变得非常重要。当神经元数量较小时, 主要误差来自逼近空间本身; 当神经元数量较大时, 理论逼近误差下降, 积分误差必须同步减小, 否则会限制最终精度。所需积分点数实验清楚地展示了神经元数量与积分点数之间的耦合关系。

第三，矩阵条件数是该问题中的核心数值困难。即使逼近空间在理论上具有良好性质，如果 Gram 矩阵或最小二乘矩阵病态，数值解仍然可能不稳定。因此，直接求解加权最小二乘问题通常优于显式形成 normal equations。后续可以进一步研究适用于 ReLU^k 基函数的预条件方法。

6 结论与展望

本文研究了固定内部参数的 ReLU^k 有限神经元空间中的 L^2 与 H^1 投影问题。数值实验表明，该空间能够提供有效逼近，但最终精度取决于逼近误差、积分误差和数值稳定性之间的平衡。

后续可以继续从以下几个方向展开：

- 系统研究最小二乘矩阵的条件数和奇异值谱；
- 将所需积分点数曲线中的波动与矩阵病态性联系起来；
- 构造适用于 ReLU^k 基函数的预条件方法；
- 将该框架应用到椭圆型或抛物型偏微分方程的数值求解中；
- 进一步研究满足物理约束的神经元空间，例如严格无散度的神经元空间。

总的来说，本研究为理解线性化神经网络在函数逼近和偏微分方程数值求解中的表现提供了一个初步的数值分析视角，也为后续进一步研究积分误差、矩阵稳定性和高维扩展问题奠定了基础。

参考文献

- [1] X. Liu, T. Mao and J. Xu. *Integral Representations of Sobolev Spaces via ReLU^k Activation Function and Optimal Error Estimates for Linearized Networks*. arXiv preprint, 2025.
- [2] T. Mao, J. Xu and X. Xu. *Solving High-Dimensional PDEs Using Linearized Neural Networks*. arXiv preprint, 2026.
- [3] X. Liu, T. Mao and J. Xu. *The Stability of Shallow Neural Networks on Spheres: A Sharp Spectral Analysis*. arXiv preprint, 2025.
- [4] J. He, X. Liu and Z. Tian. *Divergence-free Linearized Neural Networks: Integral Representation and Optimal Approximation Rates*. arXiv preprint, 2026.